第三届“兴智杯” · 大模型智能体关键能力技术创新赛 · 方向 3 开放赋能智能体

织序 WeaveOrder
可审计的任务编排智能体

用户给一句自然语言目标，织序把它织成可执行、可校验、可追溯的任务 DAG：并行执行、确定性校验、三级失败恢复、高风险动作人工审批——并且用消融实验证明，编排层的每一个组件都有可测量的贡献。

版本
v0.4.0 · 2026-10

基础模型
书生 Intern-S2（TokenPlan · OpenAI 兼容）

运行形态
CLI · Web 控制台 · MCP Server · A2A Server

参赛者
兰儒恺（个人开发者）

代码仓库
github.com/iakRulan/weaveorder-agent

演示视频
在线观看（1080P）



在线体验：http://39.105.68.73:8000（公开演示，Mock 模式，无需 API Key）· A2A：39.105.68.73:8001/.well-known/agent-card.json
本地亦可 `python agent.py --mock "…"` / `python a2a_server.py`。报告中全部数字与截图均来自真实运行，可按 §7 复现。

01 问题：从一句话到可交付，中间隔着编排

> 「帮我安排 10 月 28 日上海到深圳的客户拜访，预算 3000 元」——这句话和一个可以提交给财务与客户的差旅方案之间，隔着政策检索、多轮比价、费用计算、合规核查、人工审批和失败恢复。**把这一段交给提示词，得到的是概率；把它交给编排层，得到的是可审计的交付物。**

单 Agent 直接执行，输在哪里

我们用同一本书生 Intern-S2 做了对照：让模型以原生 Function Calling 自主循环调用工具（业界最常见的 ReAct 式做法，即织序的 `agent` 模式），与织序的 DAG 编排模式执行同一个差旅任务：

指标（同一任务 T01, live）	ReAct 单 Agent	织序 DAG 编排	差异来源
Token 消耗	49,781	**7,034**（7.1× 优势）	Blackboard 引用代替把长 JSON 反复塞回上下文
工具调用次数	9 次	7 次	计划先行，无试错型调用
预算越权风险	靠提示词约束	**引擎强制校验**	risk≥2 动作硬闸门
结论可追溯	对话历史	**全量事件 Trace**	每个数字反查到工具调用

这不是实现优劣问题，而是结构问题：ReAct 循环把「计划、执行、校验、恢复」全部压进模型上下文，每一步都为上一步的全部历史付费；编排层把四件事拆开，各自用确定性机制兜底，模型只做选择与解释。

现有编排框架没有回答的问题

框架解决「怎么搭」

LangGraph、CrewAI 等框架提供图/角色抽象，但编排逻辑的正确性仍然依赖使用者自行验证——组件拆掉之后系统质量如何，没有人量化。

织序回答「为什么可靠」

织序把校验、修复、重规划、审批做成引擎的一等公民，并用消融实验给出组件级证据：**拆掉校验层，任务通过率从 5/5 崩到 1/5（mock）与 3/3 崩到 1/3（live）**。可靠性不是宣称，是测量结果。

02 方法：七个角色、一条 DAG、三级恢复



图 1 · 织序编排引擎：模型负责理解与选择，引擎负责依赖、状态、校验、恢复与审计

设计决策与理由

决策	做法	解决的实际问题
确定性优先	日期/城市/费用/政策阈值由代码判定；计算封装为工具（`compute_trip_cost`），禁止模型心算	数值幻觉：报告里的每个数字都能反查到工具返回
三级失败恢复	步骤内确定性修复（放宽过严过滤）→ 预算组合优化器（预算内最优/降级+审批）→ LLM Replanner（只改未完成子图）	空结果、超预算、不可达：每类故障有明确恢复路径，绝不静默失败
风险分级审批	工具声明风险等级；risk≥2 的动作引擎级暂停，批准/拒绝/超时全部写入 Trace	“能不能自动执行”成为引擎能力而非提示词约定
角色化模型路由	Intern-S2 负责规划/重规划，轻量模型负责审查、抽取、叙事；结构化任务显式关闭思考	规划耗时从分钟级降到秒级，成本可控
上下文工程	Blackboard 结果引用（`$s2.best.price`）、工具描述压缩、结果摘要、Agent Skills 注入	Token 消耗为单 Agent 模式的 1/7
长周期记忆	偏好画像 + 历史行程；白名单键 + 置信度 + 敏感信息过滤；规则/模型双通道写入	跨运行个性化，且不覆盖本次显式约束

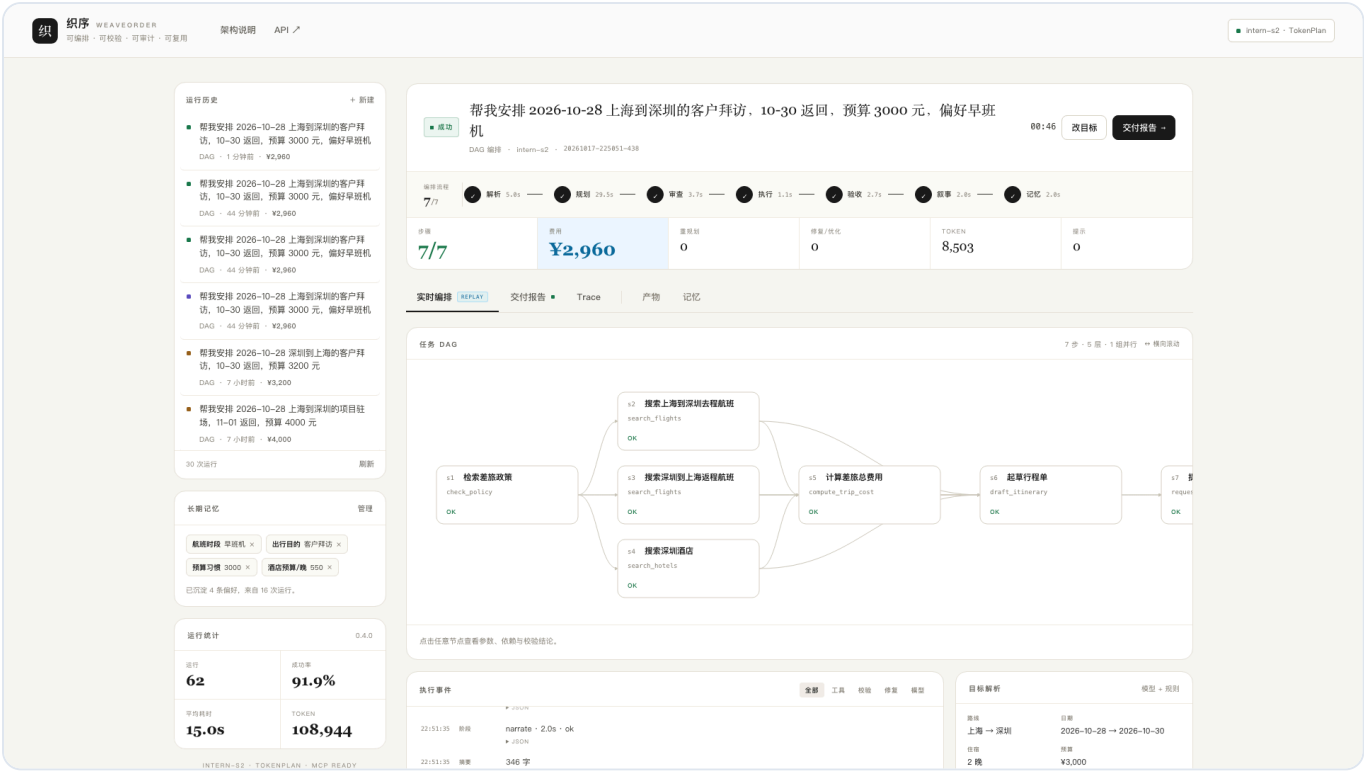


图 2 · Intern-S2 真实运行（run 20261017-225051-438）：阶段耗时（解析 5.0s → 规划 29.5s → 执行 1.1s → 验收 2.7s）、7/7 步、¥2,960、8,503 tokens、并行 DAG 与记忆面板同屏可见

03 开放赋能：三协议互通的 harness 本体

> 织序本身就是 harness。按照三大开放标准实现对外互通，全部手写、零新增第三方依赖，Python 3.9 即可运行——可复现性本身就是评分标准之一。

A2A 智能体互通

实现 Agent2Agent 开放协议（Linux Foundation）：AgentCard 自动发现、`message/send`、SSE 流式、任务查询与取消，兼容 v1.0 方法命名。

MCP 工具输出

stdio MCP Server 向任意 MCP harness 暴露 9 个类型化工具，支持 2025-06-18 / 2025-03-26 / 2024-11-05 三代协议版本协商。

Agent Skills 技能包

按 agentskills.io 开放标准加载 SKILL.md：技能注入 Agent 提示（上下文工程），并自动进入 A2A 能力声明。

选型：为什么不基于现成框架重写

候选（2026-10 最新版）	Python 门槛	结论
mcp 官方 SDK 2.3 / a2a-sdk 1.2 / mem0ai 2.2 / langgraph 1.2 / crewai 1.15	均要求 ≥3.10	不引入。按官方规范手写协议层，锁定 3.9+ 零重依赖

候选（2026-10 最新版）	Python 门槛	结论
agentscope 2.0	≥3.11	同上
自研引擎（织序）	3.9+，仅 fastapi/uvicorn/httpx/pydantic	编排层是本作品的技术贡献，引擎即 harness；依赖越少，评委复现成本越低

实测：一条命令成为 A2A 智能体

```
.venv/bin/python a2a_server.py --port 8001   # 默认 mock 模式，无需 API Key

GET  /.well-known/agent-card.json   → 名称/技能/接口自动声明（含 2 个 Agent Skill）
POST /  message/send                → 8ms 完成一次完整编排，返回 Task + 报告 artifacts
POST /  message/stream              → SSE: working → artifactUpdate → completed
```

同一个引擎由此获得三种调用形态：人用 Web 控制台、外部 harness 经 MCP 用工具、远程智能体经 A2A 委托任务——**开放赋能不是加了适配层，而是引擎的原生形态。**

04 证据：消融实验定位每个组件的贡献

> 评测的目标不是刷分，而是回答一个问题：**编排层的可靠性来自哪里？**我们为引擎内置了消融开关（`verify / replan / parallel`），对同一任务集在确定性与真实模型两种条件下做组件级对照。

核心结果：拆掉校验层，系统质量崩塌

5/5 → 3/3
完整织序（ours）
mock 5 任务 / live 3 任务全过

1/5 → 1/3
w/o Verifier
预算无解被误报 ok；注入故障扩散失败

变体	Mock 通过	Live 通过 (Intern-S2×12)	关键观察
`ours`	**5/5**	**3/3**	预算无解 → 显式降级 + 审批；注入故障 → 步骤内修复恢复
`w/o-verifier`	1/5	1/3	¥2960 方案在 ¥2000 预算下被误报成功；故障注入后连烧 2 轮重规划仍失败
`w/o-replanner`	5/5	3/3	本组故障在确定性修复覆盖内——纵深防御：拆掉一层，下一层兜住
`serial-exec`	5/5	3/3	固定串行流水线；正确性相同，并行收益体现为 `parallel_rounds` 结构指标

两个结论：① 校验层是约束满足率的决定性组件——它在 mock 与 live 双条件下都是唯一的崩塌点，去掉它省下的每秒时间都换来不可交付的结果；② 恢复链的顺序有价值——`w/o-verifier` 的注入任务浪费 2 轮 LLM 重规划仍然失败，反证「先确定性校验、后模型重规划」的设计顺序。

跨场景验证：同一套校验原语在第二场景同样成立

经营分析场景（CSV → SQL 聚合 → 报告，标准库 sqlite3 真执行）对校验层做了同一组对照——渲染时故意算错关键环比，校验开/关两条路径：

分析场景用例	结果	观察
华东数码骤降归因（A01）	✅ 6/6 之一	报告给出 **-58.4%**（品类）/ **-22.3%**（大区）/ **-8.7%**（全国），与评测脚本独立重算的黄金值逐位一致
注入 + 校验开（A05）	❌ 被拦截	「报告值 -29.2 与数据源重算值 -58.4 不一致，已拦截，不会发布」
注入 + 校验关（A06）	⚠️ 错误发布	算错一半的 **-29.2%** 直接进入交付报告——差旅与分析两个领域，崩塌模式完全一致
数据不覆盖的大区（A04）	✅ 诚实失败	数据源不覆盖西北 → 明确失败，不编造、不外推

这组对照同时兑现了 §5.2 的承诺：**确定性校验不是差旅业务的特判，而是域无关的引擎原语。**

主评测：三条通道全部通过

通道	结果	覆盖
Mock 确定性回归	**12/12**（0.1s）	标准/降级/失败/缺日期/中文日期/反向路线/1晚/4晚
Live · Intern-S2 规划路由	**2/2**	T01 标准差旅 ¥2960 · T13 自主 Agent
Live · Qwen 全快模型	**4/4**（89.3s）	含预算无解降级、失败审计、Agent 模式

Mock 与 live 双重验证是刻意的设计：确定性数据源让 mock 回归精确到元（费用断言误差 ≤1 元），可复现、秒级；真实模型通道证明同样的编排逻辑在概率性组件之上依然成立。**两条通道用的是同一套引擎、同一套校验——换掉模型，编排能力不变。**

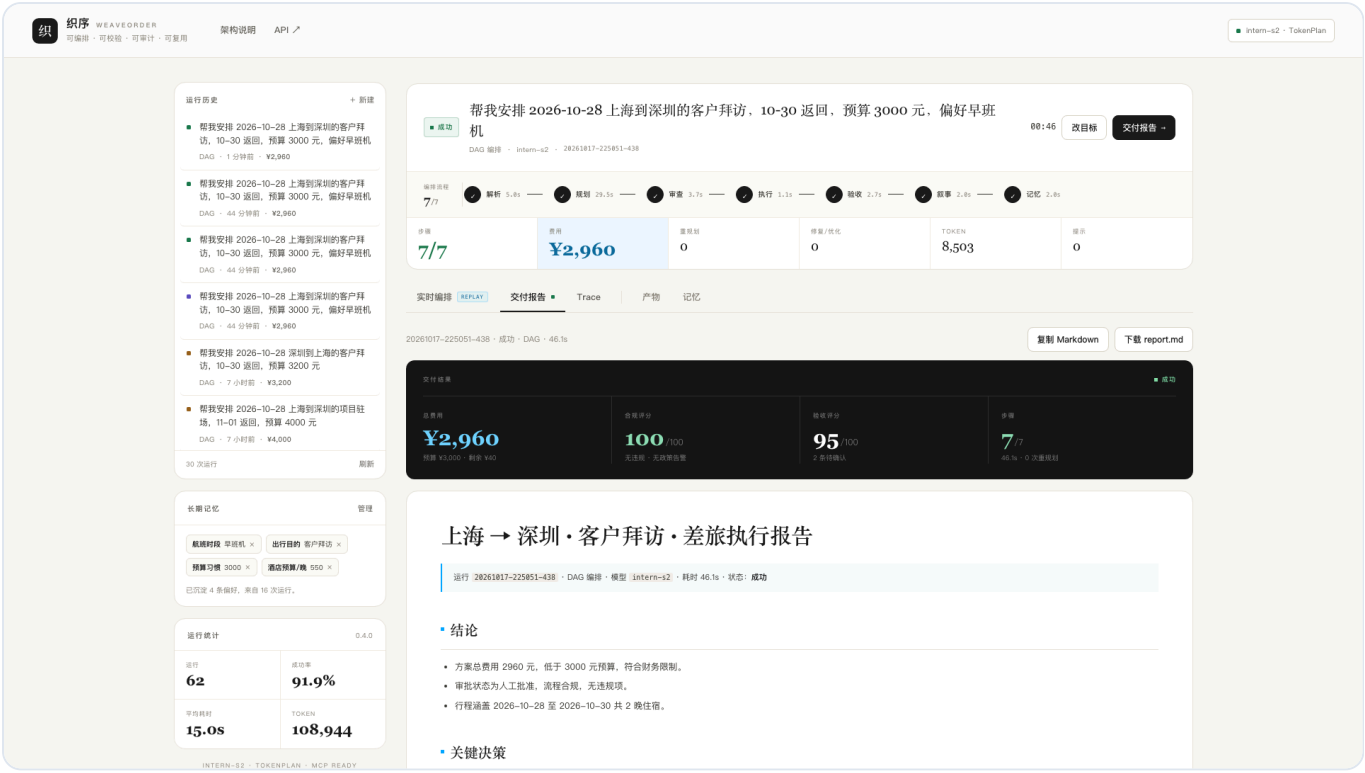


图 3 · 交付报告：总费用 ¥2,960 / 预算 ¥3,000、政策合规评分 100/100、验收评分 95/100；报告正文每个数字都可经 Trace 回查到工具调用（7/7 步 · 46.1s · 0 次重规划）

05 工程：把书生模型用稳的四个细节

> 真实模型接入的深度体现在边界情况的处理上。以下每一条都来自真实故障与修复，全部有代码与 Trace 佐证。

思考模式的分角色控制

Intern-S2 默认输出 `reasoning_content`，结构化任务会被思考 token 吃满 `max_tokens` 导致空响应。织序按角色路由：结构化抽取显式关闭思考并自动放大额度重试，规划任务保留深度思考开关——规划耗时从分钟级降到秒级。

JSON 输出三层加固

优先 `response_format=json_object`；失败时从混合文本中抽取 JSON；再失败交给修复器。Planner 同时做字段适配（模型爱写 `dag/params`），最终以 Schema 校验为准——模型输出永远不直接进执行器。

计划的后验校验

LLM 计划必须通过静态校验：工具必须存在、必填参数齐全、依赖无环、步数受控。校验失败自动回退规则规划器——系统永远可运行，降级显式可见。

环境兼容的防御

自动修复 httpx 0.28 对 `NO_PROXY=[::1]` 的解析崩溃；只读工具失败自动重试一次、写操作不重试避免副作用；超时与风险等级在工具注册表统一声明。

长期记忆采用白名单键 + 置信度阈值（0.7）+ 敏感信息过滤，规则与模型双通道写入且互不覆盖：个性化建立在可审计的数据边界内。记忆接口与外部记忆服务同构，可平滑替换后端。

06 适用边界与演进方向

数据源：确定性设计

内置确定性航班/酒店数据源是面向比赛场景的刻意选择：评委无 Key 可完整复现，评测断言精确到元。接入真实票务只需替换 `core/catalog.py` 一个模块——工具注册表与校验层不用改。

第二场景：经营分析（v0.4 已实现）

`file_read / sql_query（标准库 sqlite3 真执行）/ report_render` 与差旅共用同一套引擎原语（注册表、Trace、确定性校验、产物布局），只换工具集。6/6 分析评测通过，黄金值由评测脚本独立重算；数据不覆盖的大区诚实失败，缺失值只披露不插补。

多 Agent 分工（Planner Agent / Booking Agent / Policy Agent）、记忆后端外部化（向量库 + 用户隔离）同属演进方向；当前版本的多智能体协同已在角色层完成（7 角色、独立提示词与模型路由）。

07 复现与体验

```
# ① 无 Key 体验完整链路（mock：规则规划 + 确定性数据源）
git clone git@github.com:iakRulan/weaveorder-agent.git && cd weaveorder
python3 -m venv .venv && source .venv/bin/activate && pip install -r requirements.txt
python agent.py --mock --yes "帮我安排 2026-10-28 上海到深圳的客户拜访，10-30 返回，预算 3000 元"

# ② 真实书生模型（配置 .env 后）
python agent.py --yes "帮我安排 2026-10-28 上海到深圳的客户拜访，10-30 返回，预算 3000 元"
python agent.py --yes --mode agent "…"          # 原生 Function Calling 对照

# ③ Web 控制台 / MCP / A2A
.venv/bin/uvicorn app.server:app --port 8000     # SSE 实时编排 + 审批闸门
.venv/bin/python mcp_server.py                   # 9 个工具供任意 MCP harness 调用
.venv/bin/python a2a_server.py --port 8001       # A2A 智能体（无 Key 可公开部署）

# ④ 评测与消融
.venv/bin/python eval/run_eval.py --mode mock                       # 12/12 回归
.venv/bin/python eval/run_eval.py --suite ablation --mode mock      # 消融（确定性）
.venv/bin/python eval/run_eval.py --suite ablation --mode live --task T01 --task T02
```

材料	链接 / 位置
代码仓库（公开）	github.com/iakRulan/weaveorder-agent
演示视频（1080P · ≤5 分钟）	github.com/iakRulan/weaveorder-agent/raw/main/docs/demo.mp4

材料	链接 / 位置
评测结果	`eval/results-mock.md` · `results-live-intern.md` · `results-live-qwen.md` · `results-ablation-mock.md` · `results-ablation-live.md`
在线体验（公开演示）	http://39.105.68.73:8000（Mock 模式，无需 Key；A2A 见 AgentCard）
技术方案 / 提交清单	`docs/02-技术方案.md` · `docs/03-提交材料清单.md`

18/18	6/6	5→1	2+3	0
双场景回归（差旅 12 + 分析 6）	Live 通过（Intern-S2 + Qwen）	消融：拆掉校验层的通过率崩塌	业务场景 + 开放协议	新增第三方依赖

织序证明的事情很具体：**基于书生大模型，用一套可审计的编排层，把一句话目标变成每个数字可回查、每个高风险动作有人把关、每个组件贡献可测量的交付物。**这套能力今天就可以被任何 MCP harness、任何 A2A 客户端、任何 Agent Skills 加载器直接使用。